

MODALIDADE VISUAL

MODALIDADE TABULAR




Imagem dermatoscópica

224 × 224 × 3 (RGB)

MedSigLIP — Vision Encoder

(vision_tower do MedGemma 4B)
ViT · 27 blocos Transformer · ~400M parâmetros
 CONGELADO (sem gradiente)

pixels

tokens × 1152

Mean pooling dos tokens → 1152-d

embeddings pré-computados
1× e mantidos em cache

CABEÇA TREINÁVEL (~330k parâmetros)

Projeção visual

LayerNorm(1152) → Linear 1152 → 256
GELU → Dropout(0,1)

256-d

Concatenação → 512-d

512-d

Cabeça de classificação

Linear 512 → 256 → GELU → Dropout(0,2)
Linear 256 → 5 → logits

logits (5)

Softmax → argmax

Opcional: prediz MEL se
 $P(\text{MEL}) \geq \tau$ (calibrado na validação)

Treino: Focal Loss

$\gamma = 2 \cdot \alpha = \text{inverse_sqrt}$
label smoothing = 0,05

BCC

Carcinoma basocelular

NEV

Nevo

MEL

Melanoma

SK

Ceratose seborreica

MISC

Outras lesões



Pesos congelados (pré-treinados)



Camadas treinadas

----- Apenas no treino / pós-processamento